

计算机视觉期中作业

23307140100 郑乐怡

任务一：微调在 ImageNet 上预训练的卷积神经网络实现宠物识别

仓库地址: <https://github.com/kiwitush/pet-recognition>

模型权重下载: https://drive.google.com/drive/folders/1Qu5Qvl-hQKXgDPVcxBfNbhesU49VVka?usp=drive_link

一、数据集介绍与预处理

1.1 数据集介绍与划分

本实验使用 **Oxford-IIIT Pet Dataset**数据集, 包含 **37 个宠物品种** (12 种猫 + 25 种狗)。数据集整体较小, 训练集和测试集共计约 7400 张图像, 每张图像对应一个品种标签, 同时附带像素级的前景/背景/轮廓三分割标注 (本任务未使用, 任务三中使用)。

采用 **官方提供的 trainval / test 划分**, 并在此基础上将 `trainval` 进一步按 **85/15 比例**随机划分为训练集和验证集。

划分时固定随机种子 `seed=42`, 确保每次实验使用相同的划分, 保证结果可复现。测试集仅用于最终评估, 不参与训练过程。

集合	样本数
训练集 (Train)	~3128
验证集 (Val)	~552
测试集 (Test)	~3669

1.2 数据预处理与增强

对训练集、验证集和测试集的所有图像均进行以下处理:

- 尺寸统一**: 由于预训练 ResNet 仅接受 224×224 的输入, 模型输入尺寸统一为 224×224 。
- 归一化**: 使用 ImageNet 数据集的均值和标准差进行通道归一化, 与预训练 backbone 的输入分布保持一致:

$$\mu = [0.485, 0.456, 0.406] \quad \sigma = [0.229, 0.224, 0.225]$$

为提升模型的泛化能力, **训练集**采用以下流水线进行数据增强。

步骤	操作	参数	说明
1	RandomResizedCrop	scale=(0.8, 1.0), ratio=(0.9, 1.1)	随机选取原图 80%~100% 的区域裁剪后缩放到 224×224, 宽高比在 0.9~1.1 之间随机变化
2	RandomHorizontalFlip	p=0.5	以 50% 概率将图像左右翻转
3	ColorJitter	brightness/contrast/saturation=0.2, hue=0.05	随机调整图像的亮度、对比度、饱和度 (±20%) 和色调 (±5%)
4	RandomRotation	degrees=±10, bilinear	在 ±10 度范围内随机旋转图像, 用双线性插值填充
5	RandomErasing	p=0.2, scale=(0.02, 0.10)	以 20% 概率在图像上随机遮挡一块 2%~10% 大小的区域, 用随机像素填充

二、模型结构与训练配置

2.1 Baseline 模型

Baseline 选用 **ResNet-18 / ResNet-34**, 使用在 ImageNet 上预训练的权重进行初始化。

网络结构:

layer name	output size	ResNet-18	ResNet-34
conv1	112×112	7×7 conv, 64, stride 2	7×7 conv, 64, stride 2
max pool	56×56	3×3 max pool, stride 2	3×3 max pool, stride 2
layer1	56×56	[3×3, 64; 3×3, 64] ×2	[3×3, 64; 3×3, 64] ×3
layer2	28×28	[3×3, 128; 3×3, 128] ×2	[3×3, 128; 3×3, 128] ×4
layer3	14×14	[3×3, 256; 3×3, 256] ×2	[3×3, 256; 3×3, 256] ×6
layer4	7×7	[3×3, 512; 3×3, 512] ×2	[3×3, 512; 3×3, 512] ×3
classifier	1×1	avg pool, fc-37, softmax	avg pool, fc-37, softmax

表中 [3×3, c; 3×3, c] ×N 表示该 layer 由 N 个 **BasicBlock** 堆叠, 每个 BasicBlock 包含两个 3×3 卷积 (通道数 c) + BatchNorm + ReLU, 外加残差连接。conv1 和 max pool 各自 stride=2; layer2/3/4 首个 BasicBlock 的第一个 3×3 卷积 stride=2 完成下采样, 该 block 的 shortcut 分支通过 1×1 卷积对齐通道数。提取的特征最后经过全局平均池化并送入输出节点数为 37 的**全连接层 fc-37**, 从而实现宠物的 37 分类任务。

参数比较:

模型	总参数量	权重层总数
ResNet-18	~11.2M	18
ResNet-34	~21.3M	34

预训练权重来自 `ResNet18_Weights.IMAGENET1K_V1` / `ResNet34_Weights.IMAGENET1K_V1`，仅将最后的全连接层替换为 37 分类输出，未手写 ResNet 结构。

训练时所有参数均参与微调，**backbone 使用较小学习率，分类头从头训练使用较大学习率。**

2.2 ResNet + 注意力机制

在 Baseline 基础上，在 ResNet 的 layer2、layer3、layer4 之后分别插入注意力模块（layer1 特征图尺寸较大，插入注意力模块的开销高收益小，故跳过），在 `att_block.py` 及 `attention.py` 中**手写实现**。

支持两种注意力类型：

- **SE-block (Squeeze-and-Excitation)**：通道注意力
通过全局平均池化将每个通道压缩为一个标量，经两层全连接层计算出各通道的 0-1 重要性权重，并将学习到的权重乘回原特征图，重要通道被增强，不重要通道被抑制。
- **CBAM (Convolutional Block Attention Module)**：通道注意力 + 空间注意力串联
通道注意力对输入特征图同时进行全局平均池化和全局最大池化，获取两种不同的空间上下文信息，随后通过一个共享的 MLP 对两者进行处理合并，最终生成一个通道注意力权重向量。
空间注意力在通道维度上分别进行平均池化和最大池化，得到两个二维特征图，将这两个图拼接后，通过 7×7 卷积层生成空间注意力权重图，再与输入特征图相乘，从而突出图像中的重要区域。

2.3 训练配置

优化策略：采用**差异化学习率**，默认新增全连接层和注意力模块使用较大学习率 `lr_head`，预训练 backbone 层使用较小学习率 `lr`。

优化器：使用 AdamW 优化器， $\beta_1 = 0.9$, $\beta_2 = 0.999$ 保持默认值。

学习率调度：使用余弦衰减，学习率从初始值平滑衰减至接近 0，有助于训练的后期稳定收敛。

正则化：使用 weight decay 进行 L2 正则化，并设置 label_smoothing，提升模型泛化能力。

损失函数：使用交叉熵损失

其他：启用混合精度训练减少显存占用并加速；设置早停 patience=10，验证集 accuracy 连续 10 个 epoch 不提升则终止训练

完整超参数配置汇总

参数	默认值	说明
Batch Size	32	所有实验统一使用
优化器	AdamW	所有实验统一使用

参数	默认值	说明
学习率 (backbone)	1e-4	R34 / ViT 使用 5e-5, 超参数搜索最优 2e-4
学习率 (head)	1e-3	R34 / ViT 使用 5e-4, 超参数搜索最优 2e-3
Weight Decay	1e-4	R34 / ViT / 超参数搜索最优使用 1e-3
LR 调度器	Cosine	所有实验统一使用
Label Smoothing	0.1	R34 / ViT 消融实验使用 0.15
混合精度	True	所有实验统一使用
Epochs	50	ViT 使用 80, 消融实验使用 80, 超参数搜索使用 20
早停 Patience	10	超参数搜索使用 20

2.4 ViT 模型结构

Vision Transformer (ViT) 首先将 224×224 的输入图像均匀切分为大小为 16×16 像素的不重叠 patch，共得到 14×14 = 196 个 patch。每个 patch 展平后经线性投影映射为固定维度的 token，再额外拼接一个可学习的 [CLS] token 用于最终分类，并对所有 token 加上可学习的位置编码以保留空间信息。

序列随后送入 12 层 Transformer Encoder，每层由 Multi-Head Self-Attention 和 MLP 块通过残差连接串联，LayerNorm 置于每个子层之前。多头自注意力通过计算任意两个 patch 之间的注意力权重，从第一层起即建立全局交互。MLP 块为两层 GELU 激活的全连接，中间隐层维度为 embed_dim 的 4 倍。


本任务通过 `timm` 库加载 ImageNet-21k 预训练权重，未手写 Transformer 结构。

配置项	ViT-Tiny/16	ViT-Small/16
Patch Size	16×16	16×16
序列长度 (Patch 数量)	196	196
Embedding 维度	192	384
注意力头数	3	6
Encoder 层数	12	12
MLP 隐层维度	768	1536
总参数量	5.7M	22M

三、Baseline 训练结果


使用默认配置训练 **ResNet-18**:

- 训练 Epoch: 30 / 50 (触发早停)
- 最佳 Epoch: 19
- last_train_acc: 0.9994
- best_val_acc: **0.9221**
- test_acc: **0.8992**
- 训练耗时: 21.6 min



训练 **ResNet-34** ($lr=5e-5$, $lr_head=5e-4$, $weight_decay=1e-3$, $label_smoothing=0.15$) :

- 训练 Epoch: 35 / 50 (触发早停)
- 最佳 Epoch: 24
- last_train_acc: 0.9994
- best_val_acc: **0.9438**
- test_acc: **0.9087**
- 训练耗时: 31.4 min



对比分析：

模型	best_val_acc	test_acc	train_acc	val→test 跌幅
ResNet-18	92.21%	89.92%	99.94%	2.29%
ResNet-34	94.38%	90.87%	99.94%	3.51%

ResNet-34 在验证集上比 ResNet-18 高出 2.17 个百分点，但测试集优势缩小至 0.95 个百分点，**更大的模型整体性能更强，验证及测试准确率都更高，但在有限数据下过拟合倾向更明显。**


四、预训练消融实验

为验证预训练带来的提升，使用**随机初始化的 ResNet-18** 从头训练 80 个 epoch，保持网络架构完全一致。

训练随机初始化的 ResNet-18 ($lr=lr_head=1e-4$, $weight_decay=1e-4$, $label_smoothing=0.15$)：

- 训练 Epoch：43 / 80（触发早停）
- 最佳 Epoch：33
- last_train_acc：0.9923
- best_val_acc：**0.5272**
- test_acc：**0.4309**
- 训练耗时：30.4 min

训练后期 train_acc 逼近 98%，但 val_acc 仅 ~50%，泛化能力差，**过拟合严重。**



分析：

针对本任务的 ResNet-18 拥有约 11.2M 的参数量，而目标训练集仅包含约 3100 张图像，模型只是**强行记忆训练集样本**，而非学习普适的特征规律。随机初始化时模型缺乏底层视觉先验（如边缘、纹理、形状等），仅凭三千张图无法学到可泛化的特征，过拟合严重。

相比之下，基于 ImageNet 的预训练模型已具备通用视觉表征，微调仅需适配宠物分类任务，能够在特定数据集下迅速收敛并达到良好的泛化能力。

五、超参数分析

为探究学习率与权重衰减对模型性能的影响，固定训练轮数 **epochs=20**，对 ResNet-18 在 3 种学习率、3 种权重衰减共 **9 组**超参数组合上进行网格搜索。

所有组合均使用 **AdamW + Cosine 学习率衰减 + label_smoothing=0.1**，head 学习率设为 backbone 的 10 倍。

lr (backbone)	lr (head)	weight_decay	best_val_acc	最佳 epoch
2e-4	2e-3	1e-3	0.9293	9
1e-4	1e-3	5e-4	0.9257	17
1e-4	1e-3	1e-3	0.9257	17
5e-5	5e-4	1e-3	0.9257	17
5e-5	5e-4	1e-4	0.9239	12
5e-5	5e-4	5e-4	0.9239	17
1e-4	1e-3	1e-4	0.9221	17

lr (backbone)	lr (head)	weight_decay	best_val_acc	最佳 epoch
2e-4	2e-3	1e-4	0.9167	12
2e-4	2e-3	5e-4	0.9149	13

结果分析：

- 最优组合：** lr=2e-4, weight decay=1e-3 以 92.93% 的验证集正确率排名第一，且在 epoch 9 即达到最佳，收敛最快。与默认配置 (lr=1e-4, weight decay=1e-4) 的 92.21% 相比提升 0.72 个百分点，说明较大的学习率配合较强的权重衰减，效果最佳。
- 学习率的影响：** lr=2e-4 对 weight decay 高度敏感，weight decay=1e-3 时表现最佳，但 weight decay=1e-4 和 weight decay=5e-4 时反而垫底。lr=5e-5 和 lr=1e-4 则在不同 weight decay 下均保持稳定，对正则化强度的适应性更好。
- 权重衰减的影响：** weight decay=1e-3 显著优于其他两个，均值最高，说明在该数据集上施加较强的 L2 正则化是有效的。
- 训练稳定性：** lr=5e-5 和 lr=1e-4 的 val_acc 极差仅为 0.0036 和 0.0036，远小于 lr=2e-4 的 0.0144。如果追求训练稳定性优先于极限性能，lr=5e-5 或 lr=1e-4 配合 weight decay=5e-4 或 weight decay=1e-3 是更安全的选择。

余弦衰减与 epochs 相关，**epochs=50 时 lr 衰减曲线被整体拉长，每个 epoch 的实际学习率与 20 轮曲线不同**，因此无法保证 lr=2e-4, weight decay=1e-3 在更大的训练预算下仍然最优。lr=5e-5 和 lr=1e-4 的稳定性更好，在 epochs=50 时反而可能性能更好，网格搜索给出的不是绝对的全域最优超参数。

将搜索中的最优组合 lr=2e-4, weight decay=1e-3 扩展至 epochs=50 进行完整训练：

- 训练 Epoch: 48 / 50 (触发早停)
- last_train_acc: 0.9997
- best_val_acc: **0.9348**
- test_acc: **0.8942**
- 训练耗时: 46.1 min



对比 baseline 默认配置 ($lr=1e-4$, $lr_head=1e-3$), 虽然best_val_acc从 92.21% 提升至 93.48%, 但 test_acc从 89.92% 降至 89.42%, 更佳的验证集准确率并未转化为测试集上的泛化提升。

六、注意力机制

6.1 SE/CBAM


在 ResNet-18 的 layer2、layer3、layer4 之后分别插入 SE-block 或 CBAM 注意力模块，其他结构与 Baseline 保持一致。

在第一次实现中，发现如下问题：SE 和 CBAM 均通过 Sigmoid 函数将注意力权重映射到 (0, 1) 区间。默认随机初始化下，最后一层 Linear/Conv 的输出接近 0， $\text{sigmoid}(0)=0.5$ ，即每个注意力模块在训练初期会将特征图无差别地**缩减至原始幅度的 50%**。三个模块叠加后，预训练 backbone 提取的有用特征被衰减至约 12.5%，严重阻碍了初期的反向传播。

为修正这一问题，将各注意力模块 sigmoid 前最后一层的 bias 初始化为 1.0，使 $\text{sigmoid}(1.0) \approx 0.73$ ，最大程度保留预训练的视觉先验，训练过程中再逐步学习选择性抑制。

训练 ResNet-18 + SE ($\text{lr}=1\text{e-}4$, $\text{lr_head}=1\text{e-}3$, $\text{weight_decay}=1\text{e-}4$, $\text{label_smoothing}=0.1$) :


- 训练 Epoch: 35 / 50 (触发早停)
- 最佳 Epoch: 25
- last_train_acc: 0.9994
- best_val_acc: **0.9384**
- test_acc: **0.8937**
- 训练耗时: 22.9 min



训练 ResNet-18 + CBAM ($\text{lr}=1\text{e-}4$, $\text{lr_head}=1\text{e-}3$, $\text{weight_decay}=1\text{e-}4$, $\text{label_smoothing}=0.1$) :

- 训练 Epoch: 21 / 50 (触发早停)

- 最佳 Epoch: 11
- last_train_acc: 0.9990
- best_val_acc: **0.9293**
- test_acc: **0.8831**
- 训练耗时: 13.4 min



模型	best_val_acc	test_acc	最佳 epoch	val→test 跌幅	训练耗时
ResNet-18 (Baseline)	92.21%	89.92%	19	2.29%	21.6 min
ResNet-18 + SE	93.84%	89.37%	25	4.47%	22.9 min
ResNet-18 + CBAM	92.93%	88.31%	11	4.62%	13.4 min

引入 SE/CBAM 的模型虽然在验证集上准确率更高，但在测试集上甚至稍劣于 Baseline，未观察到显著的绝对性能提升。


分析原因：注意力模块从零开始随机初始化，3100 张有限的训练图像不足以让新增的注意力参数学到可泛化的通道/空间权重分布。CBAM 的空间注意力为所有通道生成同一张权重图，进一步抑制了通道间的差异化表达，导致其效果弱于仅做通道注意力的 SE。ResNet-18 网络主干的特征提取能力已接近该数据集的性能上限，注意力模块带来的额外自由度在有限数据下更多表现为过拟合而非性能增益。

6.2 ViT

为对比 CNN 与 Transformer 两种架构，进一步引入轻量级 Vision Transformer 进行实验。使用 timm 库加载 ImageNet-21k 预训练权重。


训练 ViT-Tiny/16 ($lr=5e-5$, $lr_head=5e-4$, $weight_decay=1e-3$, $label_smoothing=0.15$) :

- 参数量: **5.7M**
- 训练 Epoch: 54 / 80 (触发早停)
- 最佳 Epoch: 44
- last_train_acc: 0.9990
- best_val_acc: **0.9402**
- test_acc: **0.8992**
- 训练耗时: 39.9 min



训练 ViT-Small/16 ($lr=5e-5$, $lr_head=5e-4$, $weight_decay=1e-3$, $label_smoothing=0.15$) :

- 参数量: **22M**
- 训练 Epoch: 24 / 80 (触发早停)
- 最佳 Epoch: 14
- last_train_acc: 1.0000
- best_val_acc: **0.9565**
- test_acc: **0.9199**
- 训练耗时: 19.8 min



模型	参数量	best_val_acc	test_acc	最佳 epoch	val→test 跌幅
ResNet-18	11.2M	92.21%	89.92%	19	2.29%
ResNet-34	21.3M	94.38%	90.87%	24	3.51%
ViT-Tiny/16	5.7M	94.02%	89.92%	44	4.10%
ViT-Small/16	22M	95.65%	91.99%	14	3.66%

ViT-Small/16 的 test_acc 达到 **91.99%**，超过 ResNet-34 (90.87%) 约 1.1 个百分点，成为本实验中表现最强的模型。其参数量 (22M) 与 ResNet-34 (21.3M) 相当，收敛也更快。

ViT 架构在本任务中表现优于 ResNet，主要原因如下：

- 预训练数据量优势**：ViT 的预训练权重来自 ImageNet-21k (1400 万张图像、2.1 万类别，通过 timm 加载)，而 ResNet 权重来自 ImageNet-1k (120 万张图像、1 千类别)。前者见过的视觉模式种类远超后者，迁移到宠物细粒度分类时特征质量更高。
- 自注意力更适合细粒度分类**：宠物品种的差异往往表现在局部细节，ViT 从第一层起即建立 patch 之间的全局交互，任意两个空间位置可直接关联；而 ResNet 依赖卷积的堆叠逐步扩大感受野，需要到深层才能建立长距离依赖。
- 同量级参数下架构效率更高**：ViT-Small (22M) 与 ResNet-34 (21.3M) 参数量相当，但测试集准确率更高，且收敛更快，说明 Transformer 架构在当前任务上对每参数的表征利用更充分。
- 预训练 vs 随机初始化的注意力**：这是 ViT 优于 R18 + SE/CBAM 的核心原因，ViT 每层的多头自注意力在 ImageNet-21k 上已学会一定的关注模式，微调时只需适配新任务，而 ResNet 外加 SE/CBAM 模块**从零开始随机初始化**，3100 张训练图像不足以让注意力模块学到稳定的通道、空间权重分反而引入过拟合。

七、结果汇总与对比

实验类型	模型	参数量	预训练	lr (backbone)	lr (head)	weight decay	label smoothing	最佳 epoch	best_val_acc	test_acc	val→test 跌幅	训练耗时
Baseline	ResNet-18	11.2M	ImageNet-1k	1e-4	1e-3	1e-4	0.10	19	92.21%	89.92%	2.29%	21.6 min
Baseline	ResNet-34	21.3M	ImageNet-1k	5e-5	5e-4	1e-3	0.15	24	94.38%	90.87%	3.51%	31.4 min
消融实验	ResNet-18 (随机初始化)	11.2M	无	1e-4	1e-4	1e-4	0.15	33	52.72%	43.09%	9.63%	30.4 min
注意力机制	ResNet-18 + SE	11.2M	ImageNet-1k	1e-4	1e-3	1e-4	0.10	25	93.84%	89.37%	4.47%	22.9 min
注意力机制	ResNet-18 + CBAM	11.2M	ImageNet-1k	1e-4	1e-3	1e-4	0.10	11	92.93%	88.31%	4.62%	13.4 min
ViT	ViT-Tiny/16	5.7M	ImageNet-21k	5e-5	5e-4	1e-3	0.15	44	94.02%	89.92%	4.10%	39.9 min
ViT	ViT-Small/16	22M	ImageNet-21k	5e-5	5e-4	1e-3	0.15	14	95.65%	91.99%	3.66%	19.8 min

所有实验均使用 AdamW 优化器 + Cosine 学习率衰减 + 混合精度训练 + 早停 patience=10。ViT 实验 epochs=80，其余 epochs=50。

八、推理可视化

在 `inference.py` 中实现了单张图片预测及全测试集评估。

命令	功能
<code>python inference.py <image_path></code>	单张图片预测，输出品种名与置信度
<code>python inference.py --random [checkpoint]</code>	随机抽取一张测试集图片进行预测，保存为 <code>prediction_result.png</code>
<code>python inference.py --test [checkpoint]</code>	测试集上完整评估，输出整体 accuracy

以 ResNet-18 baseline 的随机预测结果为例，预测品种与置信度标注于图片右下角：



九、结论

本实验在 Oxford-IIIT Pet Dataset 数据集上基于 ResNet 架构实现宠物识别，探究了预训练、模型容量和注意力机制对分类性能的影响，主要结论如下：

1. **ImageNet 预训练至关重要**：随机初始化 ResNet-18 从头训练，验证集正确率仅约 53%，而预训练微调达到 92.21%，提升近 40 个百分点。在仅约 3100 张训练图像的条件下，ImageNet 预训练提供的通用视觉先验（边缘、纹理、形状）是模型泛化的关键。
2. **参数更多、更深的模型效果更好**：ResNet-34 (test_acc 90.87%) vs ResNet-18 (89.92%)，ViT-Small (91.99%) vs ViT-Tiny (89.92%)，增大模型在两个架构上均带来一致的性能提升。
3. **在 ResNet 上引入注意力机制的收益有限**：在 ResNet-18 中插入 SE/CBAM 模块后，验证集正确率有所提升但测试集增益不明显。原因可能是注意力模块的 Sigmoid 初始 bias=0 导致训练初期特征被过度衰减，修正为 bias=1.0 后有所缓解但仍不理想；且数据集规模有限注意力模块新增的参数量带来的过拟合倾向抵消了性能提升。
4. **ViT 参数效率更高**：ViT-Tiny/16 以 5.7M 参数 (ResNet-18 的 51%) 达到相同的测试集精度 89.92%，参数效率优于 CNN。但收敛慢、val→test 跌幅大，在小数据集上仍需配合更强的正则化手段。

综上，在中小规模数据集上进行图像分类微调时，选择合适的预训练主干网络、通过网格搜索确定学习率与正则化强度、采用差异化学习率策略是最关键的决策。CNN (ResNet) 在本任务上更易训练、收敛更稳定；ViT 参数效率高但需要更多数据或更强的数据增强才能发挥优势；外接注意力模块在小数据集上效果不理想。